Escuela Superior
de Ingeniería y Tecnología
Universidad de La Laguna

Inteligencia Artificia

Práctica 2. Algoritmos Genéticos

Sergio Molina Ríos



Fecha 21/10/2026

- **Tarea 5**

C/ Padre Herrera s/n
38207 La Laguna
Santa Cruz de Tenerife. España

T: 900 43 25 26

ull.es

- **Tarea 5**

  En este apartado se solicitaba realizar un análisis sobre los parámetros a usar en la tarea 6, para realizar las ejecuciones con los valores más óptimos analizados. Para ello, realicé varias ejecuciones y envíe los datos a un fichero, que se encuentra en el proyecto, en la carpeta docs/, en el que se ven los datos obtenidos y se explica la interpretación de los mismos y porqué se eligieron los parámetros elegidos

- **Tarea 6**

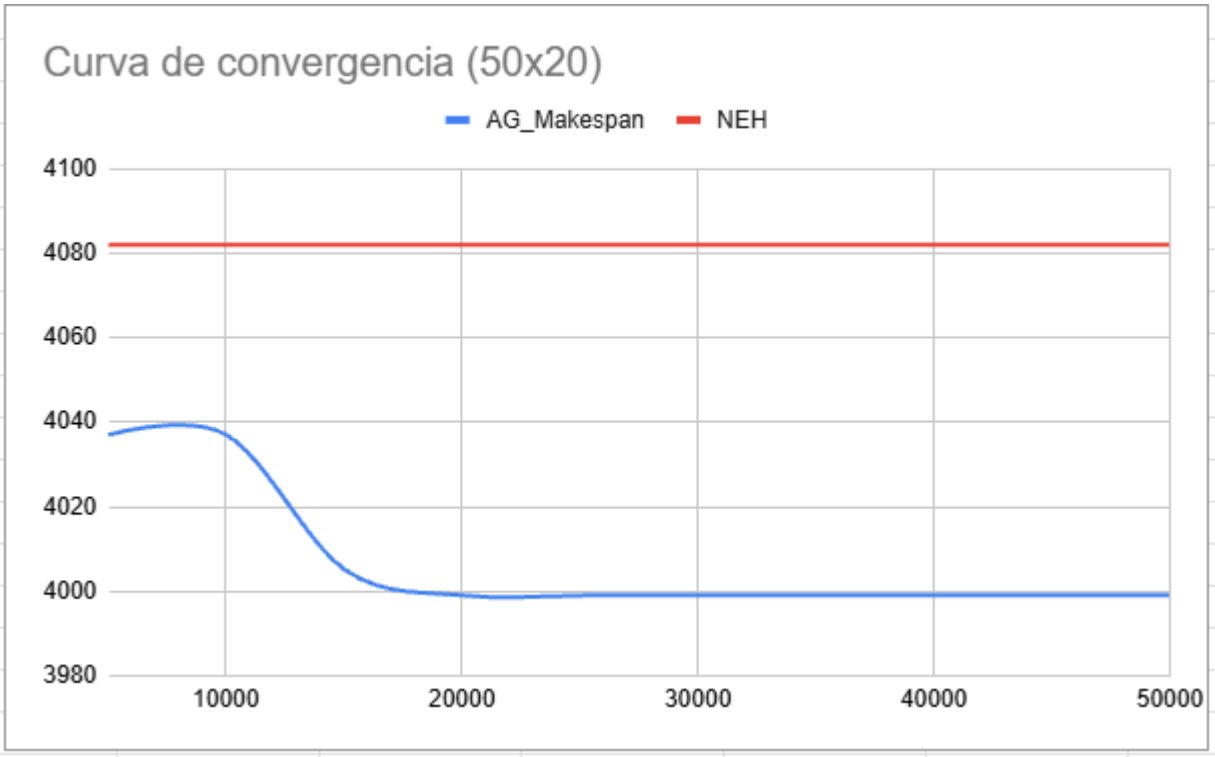
  En esta tarea, se solicitaba realizar una experimentación, realizando 10 ejecuciones independientes, cambiando la semilla, por cada instancia, y construir posteriormente una tabla y realizar unas gráficas. Habían 12 tipos de instancias, con 10 ejemplos de cada una de ellas, para esta tabla se utilizó un ejemplo de cada tipo de instancia, el acabado en 1.fsp más concretamente. La tabla resultante fue la siguiente:

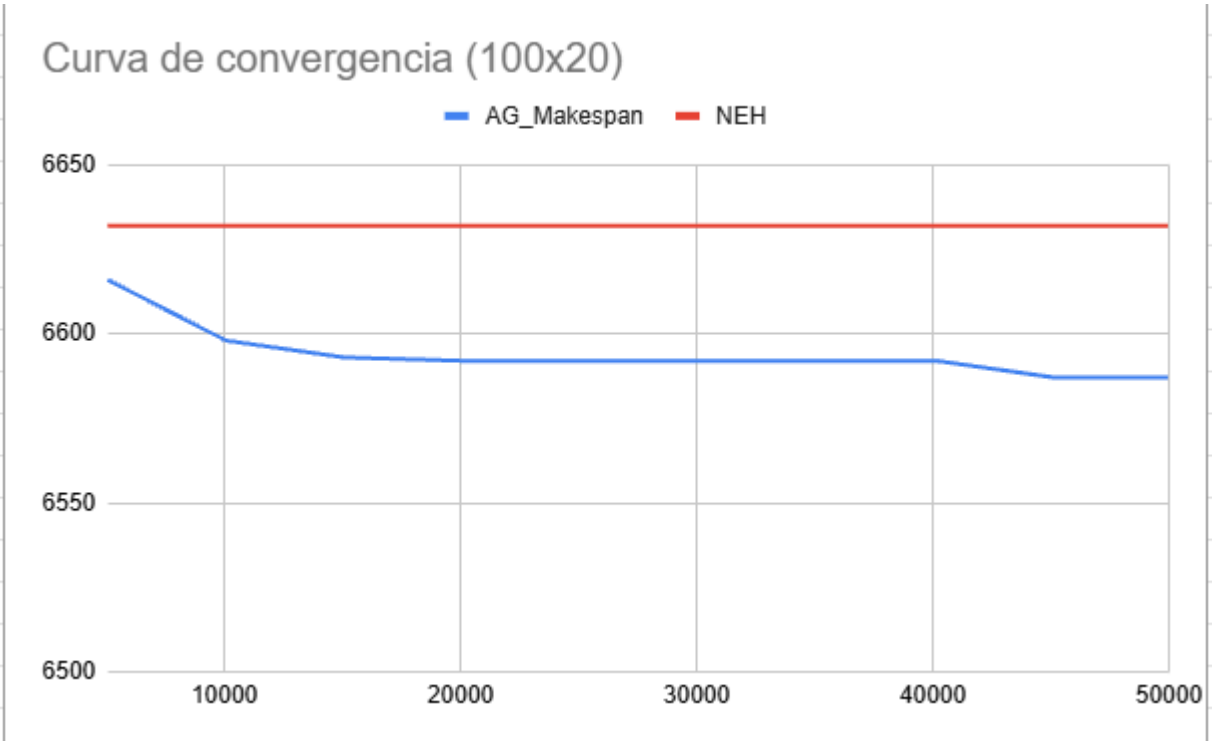
Tabla_1

Instancia	UB	NEH_Makesp	RPD_NEH	# RS_Min	RS_Media	RPD_RS_Medio	AG_Min	AG_Media	RPD_AG_M
tai20_5_1.fsp	1278	1286	0,63	1301	1317,5	3,09	1282	1285,6	0,59
tai20_10_1.fsp	1582	1680	6,19	1695	1727,4	9,19	1610	1624,5	2,69
tai20_20_1.fsp	2297	2410	4,92	2444	2463,3	7,24	2342	2361	2,79
tai50_5_1.fsp	2724	2733	0,33	2767	2796,4	2,66	2729	2729	0,18
tai50_10_1.fsp	3025	3146	4,00	3415	3437,7	13,64	3077	3094,1	2,28
tai50_20_1.fsp	3875	4082	5,34	4387	4435,6	14,47	3986	4011,1	3,51
tai100_5_1.fsp	5493	5514	0,38	5596	5633,3	2,55	5493	5507,3	0,26
tai100_10_1.fsp	5770	5853	1,44	6333	6366,6	10,34	5822	5837,6	1,17
tai100_20_1.fsp	6286	6632	5,50	7225	7264,7	15,57	6521	6561,8	4,39
tai200_10_1.fsp	10868	10967	0,91	11527	11602,3	6,76	10965	10966,8	0,91
tai200_20_1.fsp	11294	11638	3,05	12790	12860,7	13,87	11590	11606,1	2,76
tai500_20_1.fsp	26189	26674	1,85	29040	29217,3	11,56	26632	26647,3	1,75
PROMEDIO GLOB			2,88			9,25			1,94

Podemos observar que el promedio del RPD en el algoritmo aleatorio es bastante malo (9,25), el del NEH baja bastantes unidades (2,88) y finalmente, el Algoritmo Genético lo supera por casi una unidad (1,94), pudiendo ver así la eficiencia del mismo.

Ahora, vemos las gráficas generadas, para dos instancias, la primera es para la instancia 1 del tamaño 50x20, y la segunda, para la instancia 1 del tamaño 100x10


Curva de convergencia (50x20)
AG_Makespan
NEH
4100
4080
4060
4040
4020
4000
3980
10000
20000
30000
40000
50000


Curva de convergencia (100x20)
AG_Makespan
NEH
6650
6600
6550
6500
10000
20000
30000
40000
50000

Se puede observar como en las gráficas, sin variar el número de ejecuciones, la línea del NEH se mantiene recta, ya que el valor es siempre el mismo, en cambio, en el Algoritmo Genético, vemos como va mejorando con las iteraciones

- **Tarea 7**

¿Qué componente influye más?

El parámetro más “sensible” es la probabilidad de mutación, Pm. Si su valor es demasiado bajo, el algoritmo caerá rápidamente en óptimos locales, ya que, al mutar con poca frecuencia, se terminará cruzando soluciones muy parecidas entre sí; y si lo ponemos muy alto, destruirá las soluciones prometedoras una gran cantidad de veces.

¿Hay convergencia prematura?

Podemos observar como en las primeras 10.000 - 20.000 iteraciones, el algoritmo logra hacer una mejora significativa, pero en la mayoría de las veces, se atasca hasta llegar a las 50.000, formando una línea recta.

¿Cuánto mejora el AG a NEH?

En instancias pequeñas, mejora muy poco o incluso no mejora nada, debido a que con instancias tan pequeñas, NEH alcanza el óptimo o una solución muy buena. A medida que crecen las instancias, esto no ocurre, NEH no se acerca tanto al óptimo, y el algoritmo genético es capaz de mejorar y reducir el makespan en algunas unidades, mejorando RPD.